

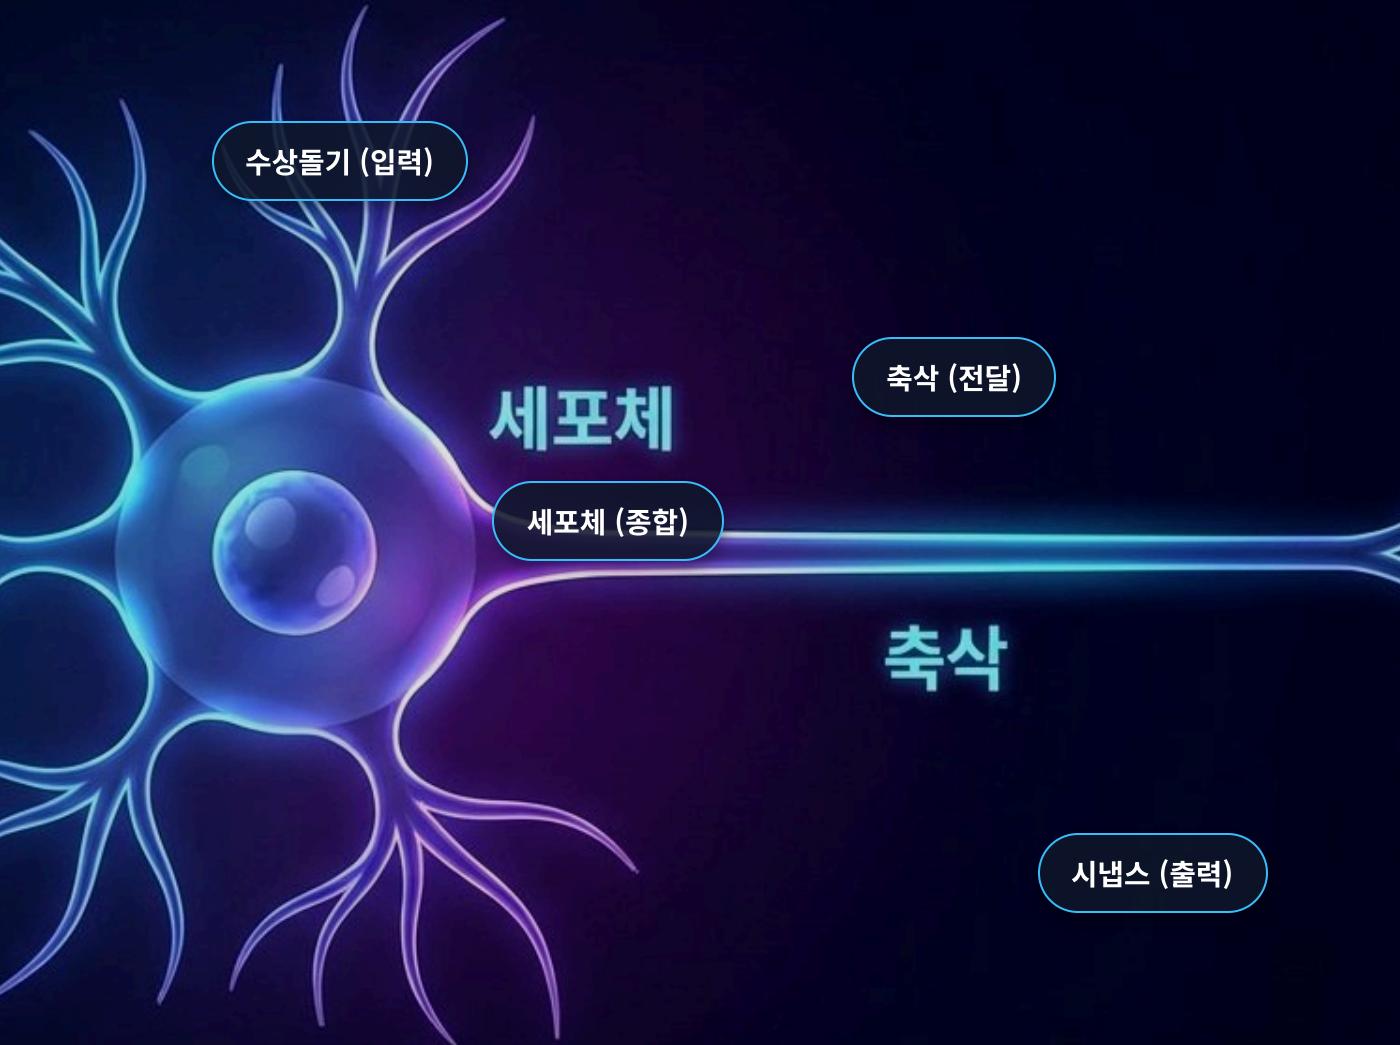


# 딥러닝의 기원: 인공 뉴런과 퍼셉트론

선형 분리의 한계와 다층 구조의 필요성

# 왜 단순한 모델로는 이미지나 음성을 인식하기 힘들었을까?

"세상은 **비선형적**으로 얹혀 있으며,  
단일 직선으로는 그 **복잡한 경계**를 그릴 수 없기 때문입니다."



## BIOLOGICAL INSPIRATION

# 생물학적 뉴런의 모방과 원리

## →] 수상돌기 (Dendrites)

외부로부터 전기 신호를 **수신**합니다.  
인공 신경망에서의 **입력(Input)**에 해당합니다.

## ■ 세포체 (Cell Body)

들어온 신호들을 모두 **합산**하고 처리합니다.  
**가중 합(Weighted Sum)** 연산이 일어나는 곳입니다.

## ⚡ 축삭 & 발화 (Axon & Fire)

합산된 신호가 임계값을 넘으면 **발화(Fire)**하여 다음 뉴런으로 전달합니다.  
**활성화 함수(Activation Function)**의 역할입니다.

# 인공 뉴런의 수학적 모델

Perceptron Formula

$$y = f( \mathbf{w} \cdot \mathbf{x} + b )$$

입력의 가중 합이 편향을 넘어설 때 활성화

**X**

입력 벡터 (Input)

외부에서 들어오는 데이터 신호  
(이미지 픽셀, 음성 파형 등)

**w**

가중치 (Weight)

입력 신호의 중요도  
학습을 통해 최적화되는 값

**b**

편향 (Bias)

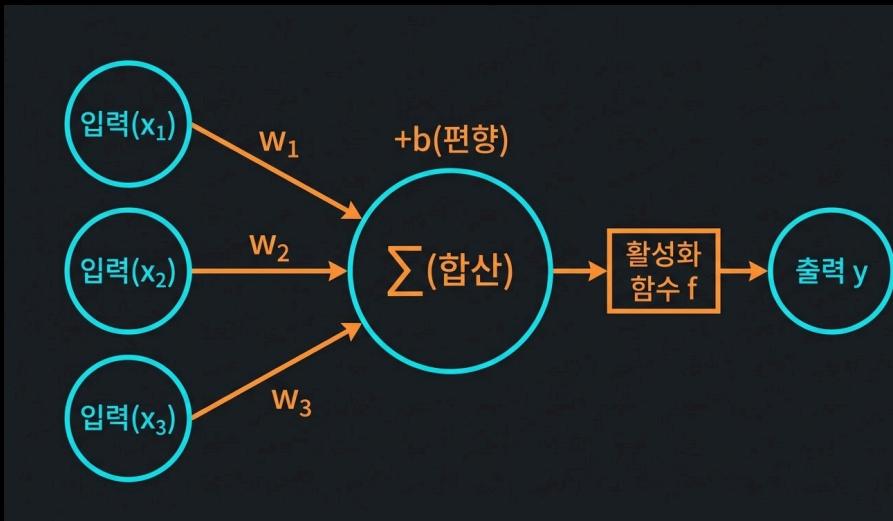
뉴런의 민감도 조절  
활성화 임계값(Threshold) 이동

**f**

활성화 함수

총합을 출력 신호(0/1)로 변환  
초기 퍼셉트론은 Step 함수 사용

Structure Visualization



## 직관적 이해:

"여러 힌트(x)에 신뢰도(w)를 곱해 합산한 점수가  
커트라인(-b)을 넘으면 합격(1), 아니면 불합격(0)"

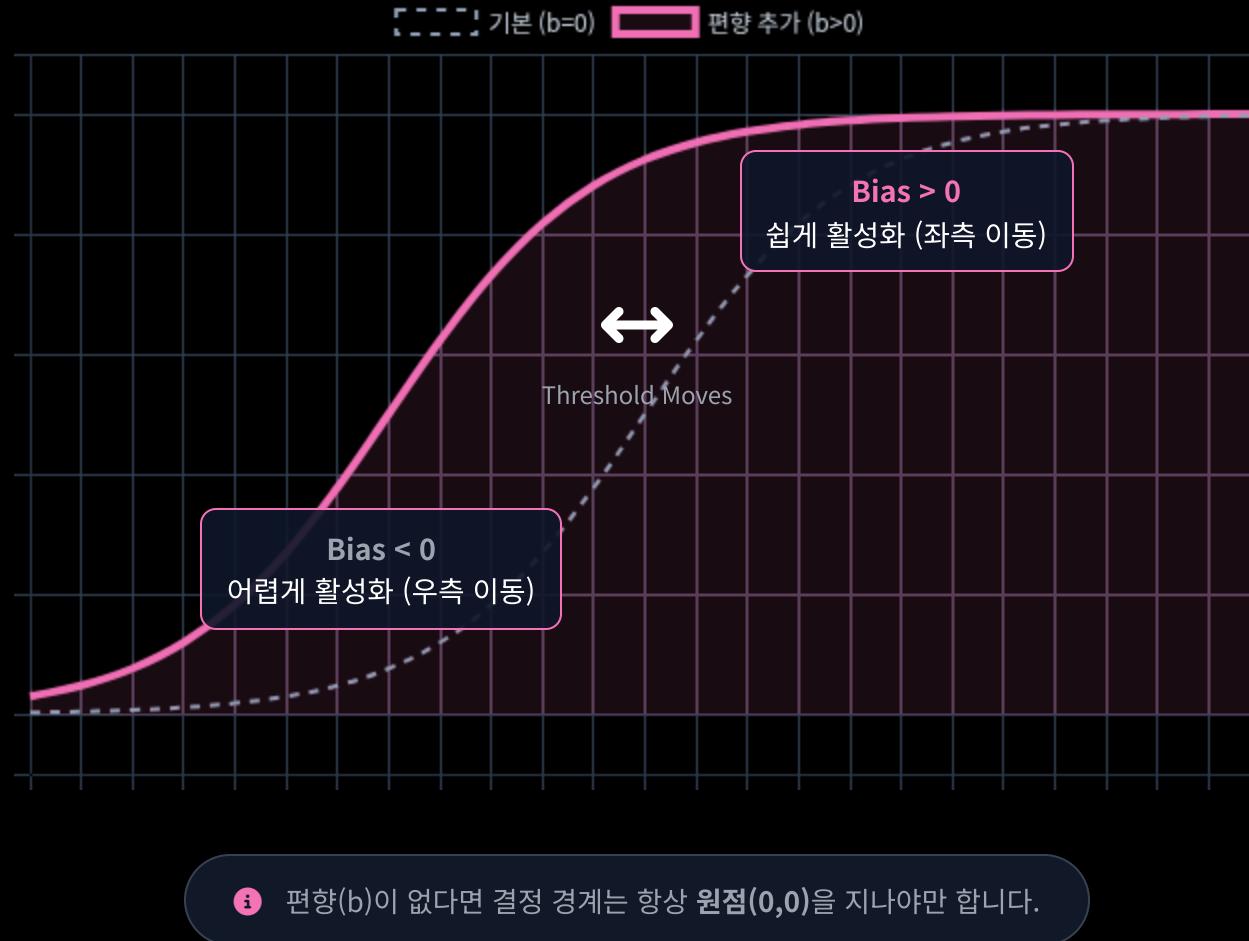
CORE CONCEPT

# 가중치( $w$ )의 의미

모델이 입력 정보를 얼마나 중요하게 생각하는지 결정합니다.



## Activation Boundary Shift



## CORE PARAMETER

### 편향 (Bias)

얼마나 민감한가?

#### ▣ 발화의 문턱값 (Threshold)

동일한 입력이 들어와도 편향에 따라 결과가 달라집니다.  
편향은 뉴런이 활성화되기 쉬운 정도를 조절합니다.

#### ▣ 민감도 조절 (Sensitivity)

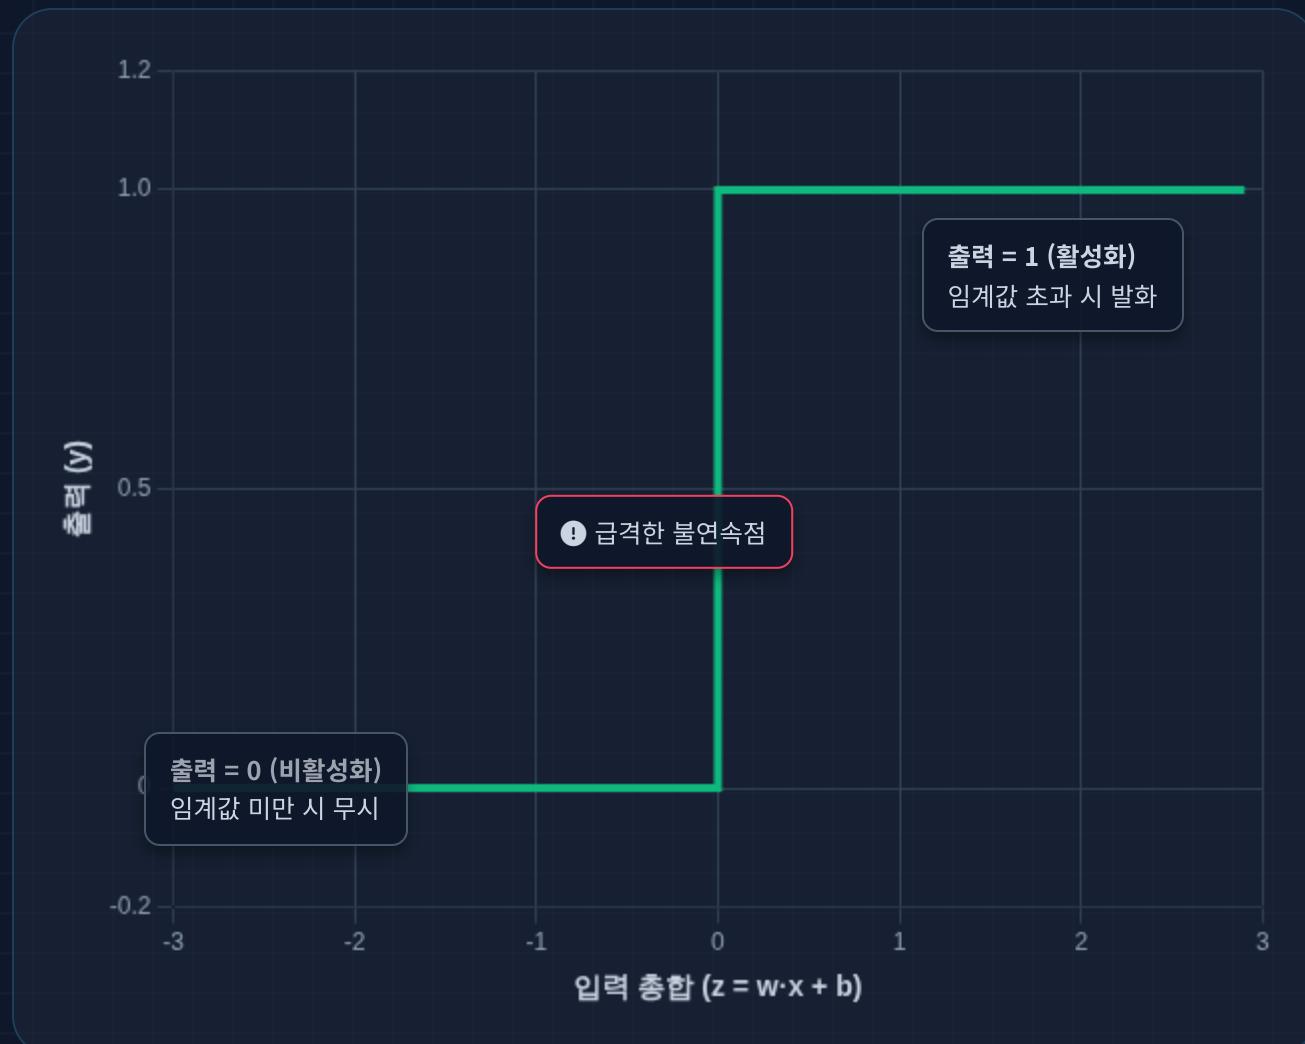
높은 편향 (+b): 작은 자극에도 쉽게 반응 (낙관적)  
낮은 편향 (-b): 큰 자극이 있어야 반응 (보수적)

#### ▣ 공간의 이동 (Shift)

그래프 상에서 활성화 함수를 **좌우로 이동**시킵니다.  
데이터 분포에 맞게 결정 경계선의 위치를 조정합니다.

# Step Function (계단 함수)

초기 퍼셉트론의 업격한 결정 방식



## MATHEMATICAL DEFINITION

$$y = \begin{cases} 1 & \text{if } w \cdot x + b > 0 \\ 0 & \text{if } w \cdot x + b \leq 0 \end{cases}$$

## 👍 명확하고 단순함

0 또는 1이라는 확실한 이진 결과를 내놓아, 디지털 논리 회로처럼 직관적이고 해석이 쉽습니다.

## 👎 학습의 한계 (미분 불가)

순간적인 변화(불연속)로 인해 미분값(기울기)이 0이거나 무한대입니다. 따라서 오차를 역추적하여 조금씩 수정하는 '딥러닝 학습(역전파)'을 적용할 수 없습니다.

# 논리 게이트 실습 – AND

● Linear Separation Possible



AND Gate

두 입력이 모두 1일 때만 1

입력 1 ( $X_1$ )	입력 2 ( $X_2$ )	출력 (Y)
0	0	0
0	1	0
1	0	0
1	1	1 ✓

규칙: 모든 조건이 충족되어야 활성화됩니다.

퍼셉트론은 이를 좌표평면 상의 점으로 인식하여 분류합니다.

↳ 선형 결정 경계 시각화



● 직선 분리 가능: 파란색 점(1,1)과 빨간색 점들(0,0, 0,1, 1,0) 사이를 단 하나의 직선으로 깨끗하게 나눌 수 있습니다.

# 논리 게이트 실습 – OR

Linear Separation Possible



OR Gate

하나의 조건만 참이어도 1

입력 1 ( $X_1$ )	입력 2 ( $X_2$ )	출력 (Y)
0	0	0
0	1	1 ✓
1	0	1 ✓
1	1	1 ✓

규칙: 입력 중 하나라도 1이면 활성화됩니다.

AND보다 발화 조건이 훨씬 관대한 편향을 가집니다.

선형 결정 경계 시각화



ⓘ 직선 분리 가능: 빨간색 점(0,0)과 나머지 세 점들(0,1, 1,0, 1,1)을 단 하나의 직선으로 완벽하게 분리할 수 있습니다.

# 선형 결정 경계

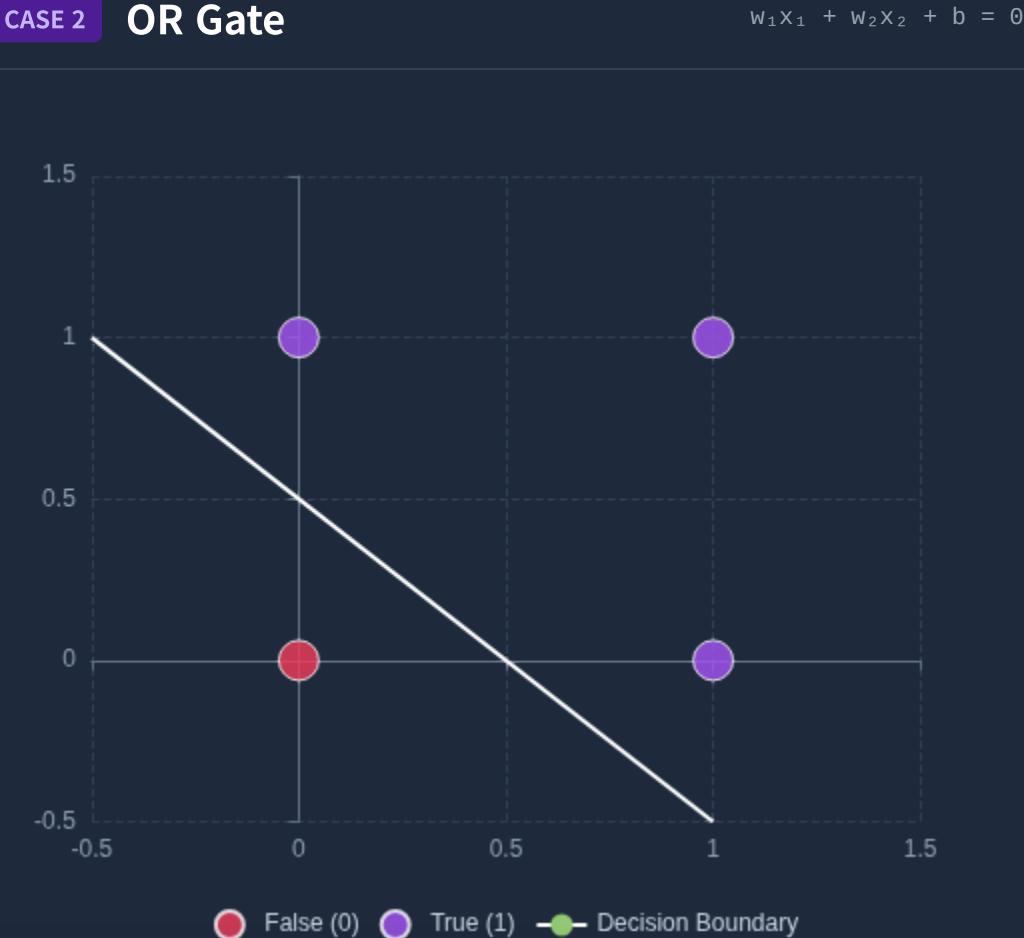
(Linear Decision Boundary)

✓ 퍼셉트론의 핵심 능력: 직선 분리

CASE 1 AND Gate



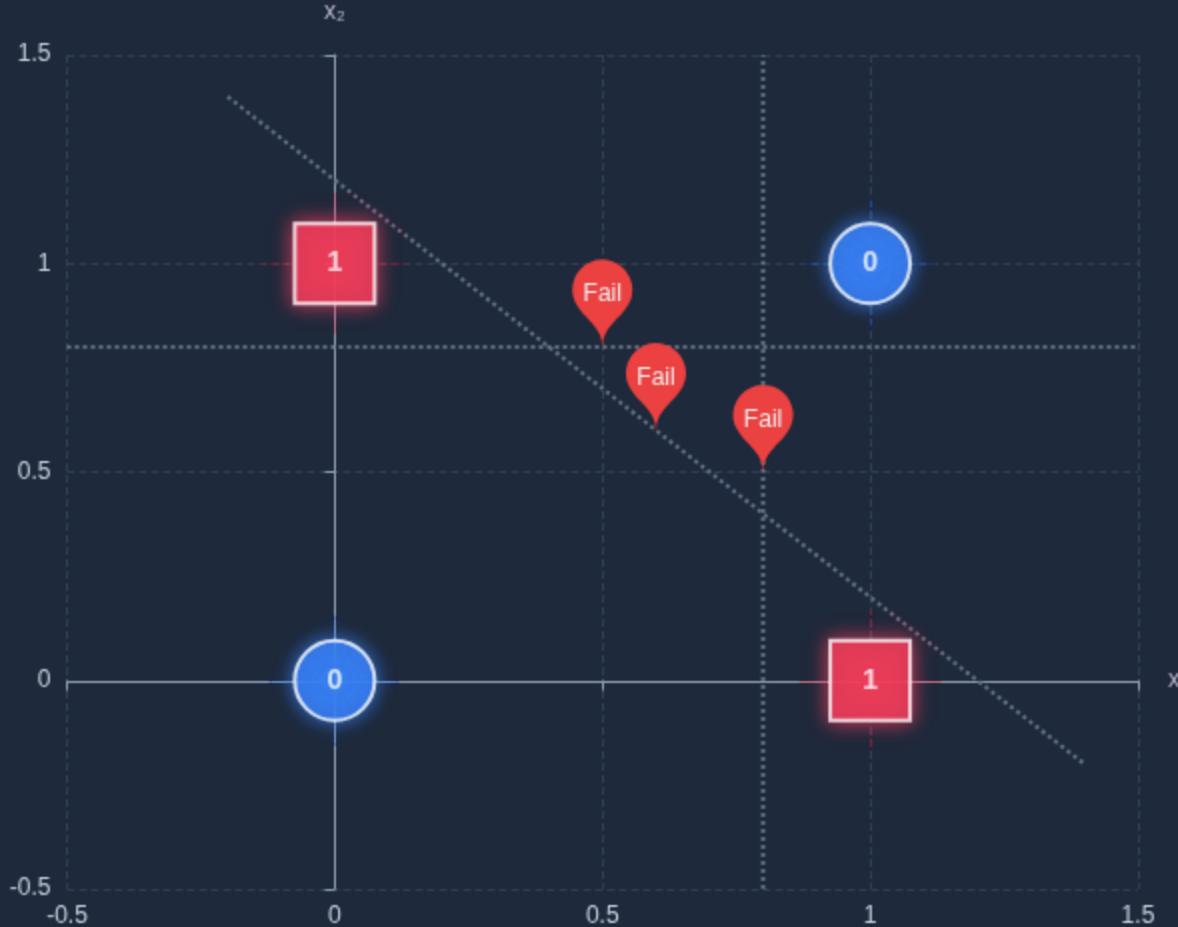
CASE 2 OR Gate



“ 단일 퍼셉트론은 데이터를 하나의 직선(초평면)으로만 나눌 수 있습니다. ”

# 퍼셉트론의 한계 – XOR의 등장

 Status  
Linearly Inseparable



 XOR Truth Table

x <sub>1</sub>	x <sub>2</sub>	y	Class
0	0	0	●
0	1	1	■
1	0	1	■
1	1	0	●

## 기하학적 딜레마

같은 클래스(색상)의 점들이 **대각선 방향**으로 서로 마주 보고 있습니다.

마치 체커보드(Checkerboard) 패턴처럼 엇갈려 있어, 직선 하나를 어디에 그어도 반드시 반대 클래스가 침범하게 됩니다.

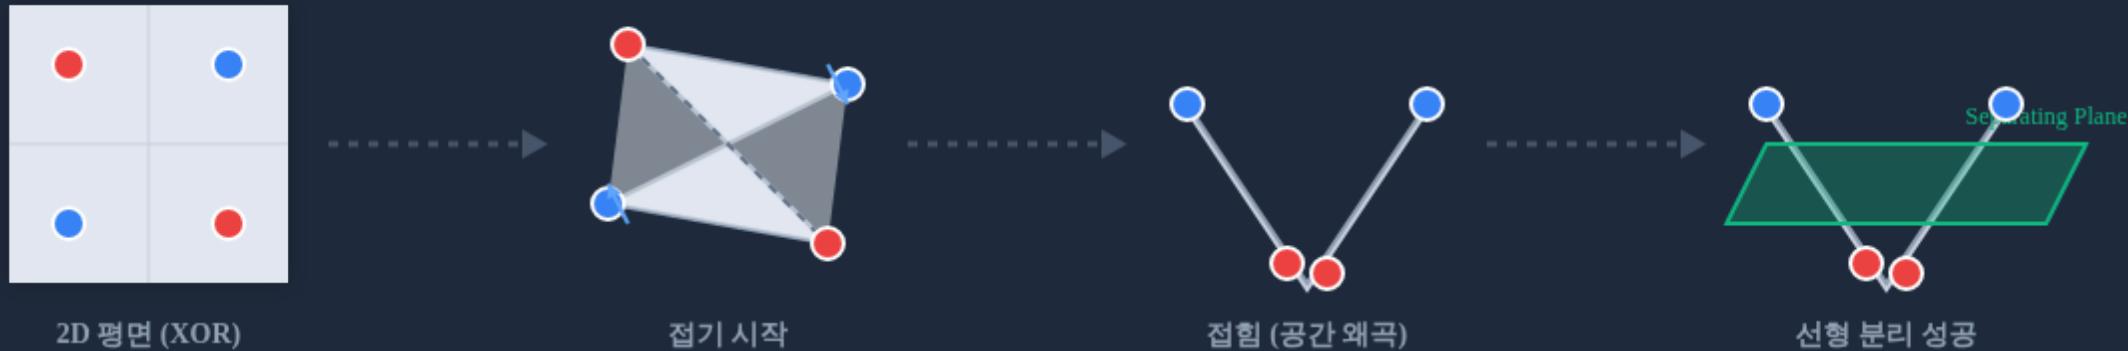


## 단일 퍼셉트론으로 해결 불가

직선 하나(선형 결정 경계)로는 절대 100% 정확도로 분류할 수 없습니다.

# 다중 구조의 아이디어 – 종이 접기

Visualization: Solving XOR by Folding Space



1

## 평면의 한계 (XOR)

XOR 데이터가 평면에 흘러져 있습니다.  
서로 마주보는 같은 색 점들 때문에  
**직선 분리가 불가능합니다.**

2

## 공간 접기 시작

온닉종이 평면을 대각선으로 접습니다.  
중앙의 **빨간 점들은 아래로,**  
양 끝의 **파란 점들은 위로 이동합니다.**

3

## 차원 변환 완료

공간이 완전히 접혀 'V'자 형태가 됩니다.  
파란 점들은 높은 곳(Top)에,  
**빨간 점들은 낮은 곳(Bottom)에 모입니다.**

4

## 선형 분리 (자르기)

이제 **가위(평면)** 하나로 자르면  
위쪽 그룹과 아래쪽 그룹을  
완벽하게 나눌 수 있습니다.

# 다층 퍼셉트론 (MLP)의 탄생

단일 층의 한계를 넘어: 은닉층(Hidden Layer)의 도입

## ◆ 은닉층의 마법

입력층과 출력층 사이에 **은닉층**을 추가합니다. 이 층은 입력 데이터를 새로운 공간으로 변환(매핑)하여, 원래는 얹혀 있던 데이터들을 **선형 분리가 가능한 형태**로 풀어줍니다.

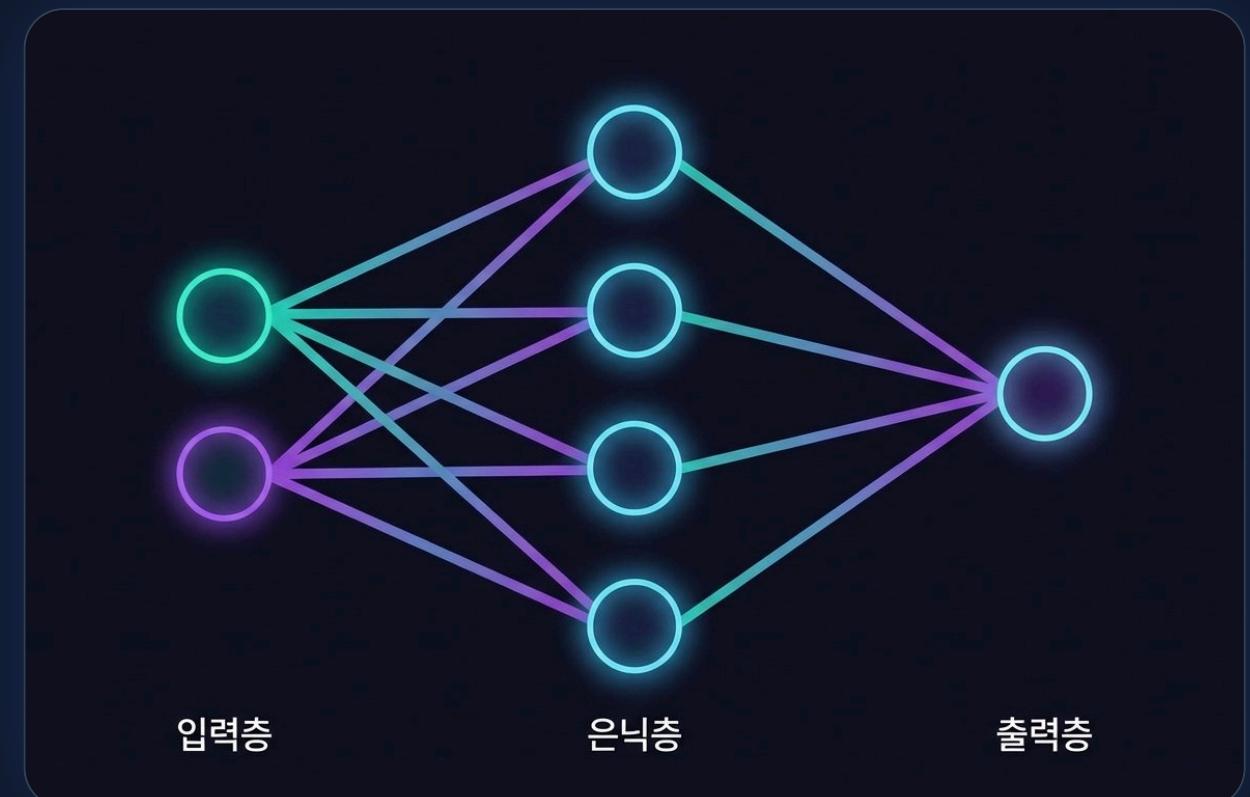
## ☒ 직선의 조합 (XOR 해결)

단일 퍼셉트론은 직선 하나만 그을 수 있지만, MLP는 여러 퍼셉트론을 결합하여 **직선 두 개 이상**을 동시에 사용합니다.

$$\text{NAND} + \text{OR} + \text{AND} = \text{XOR}$$

## ▣ 딥러닝의 시초

이 은닉층이 깊어지면(Deep) 바로 **심층 신경망(Deep Neural Network)**이 됩니다. 이제 모델은 단순한 분류를 넘어 복잡한 특징을 스스로 학습할 수 있게 되었습니다.



● 노드(Node)      — 가중치(Weight)

# 심층 신경망(DNN)으로의 확장

층이 깊어질수록 모델이 이해하는 세계의 **복잡도와 추상성**이 증가합니다.

## SHALLOW LAYERS

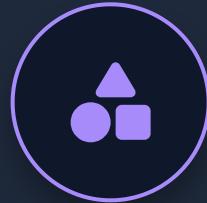


### 단순 패턴

#### Low-Level Features

입력 데이터에서 **직선, 곡선, 경계선** 같은 기초적인 시각 정보를 감지합니다. 픽셀 단위의 단순한 변화를 포착하는 단계입니다.

## MIDDLE LAYERS



### 복잡한 부분

#### Mid-Level Features

단순 패턴들이 조합되어 **눈, 코, 입, 바퀴**와 같은 사물의 '부분(Parts)'을 형성합니다. 비선형 변환을 통해 공간이 접히며 형태가 드러납니다.

## DEEP LAYERS



### 추상적 개념

#### High-Level Concepts

부분들이 결합되어 **사람 얼굴, 자동차, 고양이** 등 완성된 객체를 인식합니다. 사람이 이해하는 개념 수준의 고차원 특징입니다.



"**표현력의 폭발적 증가**" 각 층의 뉴런들이 활성화 함수(비선형성)를 통해 공간을 계속해서 접고 왜곡함으로써, 깊은 층에서는 직선으로는 상상할 수 없었던 복잡하고 추상적인 경계를 그려낼 수 있게 됩니다.

# 핵심 요약 및 결론

단층 퍼셉트론의 한계를 넘어 다층 구조로 나아가는 여정



## 선형 분류기의 한계

초기 퍼셉트론은 데이터를 **직선(Linear Boundary)** 하나로만 나눌 수 있는 단순한 모델입니다. AND, OR 같은 문제는 해결할 수 있지만 복잡한 패턴에는 무력합니다.

1



## XOR 문제의 벽

데이터가 대각선으로 교차하는 **XOR 패턴**은 그 어떤 직선으로도 100% 분리할 수 없습니다. 이는 단층 신경망이 가진 기하학적 한계를 명확히 보여줍니다.

2



## 해결책: 층(Layer) 쌓기

**은닉층(Hidden Layer)**을 추가하면 공간을 왜곡하거나 접을 수 있습니다. 여러 개의 직선을 조합하여 구부러진 경계를 만들어내는 것과 같습니다.

3



## 딥러닝의 시작

이러한 '다층 구조'와 '비선형 활성화 함수'의 결합이 오늘날 **심층 신경망(DNN)**의 기초가 되었습니다. 깊어질수록 더 복잡하고 추상적인 개념을 이해합니다.

4

NEXT LESSON

COMING UP NEXT

그렇다면, 이 복잡한 가중치( $w$ )들은 어떻게 자동으로 찾을까요? → 학습(Learning)과 역전파

