

DATA ANALYTICS & MODELING

상관 분석과 단순 선형 회귀

Correlation & Simple Linear Regression

데이터 간의 관계 규명과 예측 모델링을 위한
통계적 접근과 비즈니스 활용 전략



PRESENTER
Genspark AI



DATE
2026. 01. 14



Analysis Preview

CONTENTS

AGENDA

데이터 분석의 기초부터
예측 모델링 실습까지,
오늘의 학습 로드맵입니다.

 Total Session Time: 60 min



01



분석의 목적 및 비즈니스 질문

왜 이 분석을 하는가? (Why)

02



핵심 통계 원리

가설 검정(Hypothesis Test) & 상관 분석

03



단순 선형 회귀와 최소제곱법

예측을 위한 방정식 도출 및 OLS 원리

04



Python 실습

상관 히트맵 & 회귀 분석 모델링 시각화

05



핵심 요약 (Key Takeaways)

분석 결과 해석 시 주의사항 및 활용 팁

START POINT

비즈니스 질문

(Business Context)

데이터 분석은 항상 "질문"에서 시작됩니다.



마케팅 팀장

"이번 달 온라인 **광고비**를 늘리면, **매출**이 정말 오를까요?"



제품 기획자

"제품 **가격**이 비싸지면 **고객 만족도**는 떨어질까요?"

→ 통계적 도구로 답변을 찾아봅시다

SOLUTION TOOLS

분석 도구의 역할




상관 분석

두 변수 간의 **관계의 강도** 측정

"얼마나 친밀하게 함께 움직이는가?"

STRENGTH



회귀 분석

한 변수로 다른 변수를 **예측**하는 방정식 도출

"입력이 변하면 결과가 얼마나 변하는가?"

EQUATION



핵심: 상관 분석은 '관계의 유무'를, 회귀 분석은 '인과적 예측 모델'을 만드는 데 초점을 둡니다.

THEORY 01

가설 검정

Hypothesis Testing

데이터 패턴이 실제 의미가 있는지, 아니면 단순한 우연인지 확인하는 통계적 절차입니다.

⚖️ 법정 비유 (Analogy)

통계적 검정은 피고인이 유죄인지 무죄인지 판단하는 재판 과정과 매우 흡사합니다.



H₀ 귀무가설 (Null)


"관계가 없다"

🛡️ 무죄 추정의 원칙
(기본 상태, 의심 전)

H₁ 대립가설 (Alternative)

"의미 있는 관계가 있다"

⚠️ 검사의 주장
(입증해야 할 새로운 사실)



증거(데이터)가 충분히 강력해야 "무죄 추정"을 뒤집을 수 있습니다.

JUDGMENT CRITERIA

EVIDENCE SCORE

p-value < 0.05

유의확률이 5% 미만



VERDICT

H₀ 기각 (Reject Null)



CONCLUSION



통계적으로 유의함
Significant

CONCEPT

상관 분석

(Correlation Analysis)

두 변수가 함께 움직이는 **선형적 관계의 강도와 방향**을 분석하는 통계 기법입니다.

PEARSON

피어슨 상관계수 (r)

연속형 변수 간의 **선형 관계** 측정

- 범위: -1 ~ 1
- 이상치(Outlier)에 민감함

SPEARMAN

스피어만 상관계수 (ρ)

데이터의 **순위(Rank)** 기반 관계 분석


- 비선형적 관계나 서열 척도에 유용
- 이상치에 덜 민감함

상관관계의 시각적 이해

산점도(Scatter Plot) 패턴에 따른 상관계수 변화

강한 양의 상관관계

$r \approx +0.9$ ↗



X 증가 시 Y도 뚜렷하게 증가

상관관계 없음

$r \approx 0.0$ ✦



뚜렷한 패턴이 없음 (무작위)



주의: 상관관계 $\neq$ 인과관계

두 변수가 같이 움직인다고 해서 하나가 다른 하나의 원인이라고 단정할 수 없습니다.

단순 선형 회귀

(Simple Linear Regression)

독립변수(x)와 종속변수(y) 사이의 관계를 가장 잘 설명하는 **직선**을 찾는 분석 방법입니다.

REGRESSION EQUATION

$$y = ax + b + \varepsilon$$

a : 기울기(Slope)

b : 절편(Intercept)

ε : 오차(Error)

🔍 최소제곱법 (OLS)

데이터 포인트와 회귀선 사이의 수직 거리(잔차)의 **제곱 합(Sum of Squared Residuals)**이 최소가 되도록 a와 b를 추정합니다.



선형성
Linearity



등분산성
Homoscedasticity



정규성
Normality



이상치
Outliers


[실습 1] Iris 상관계수 계산 및 시각화

Python

```
import seaborn as sns
import matplotlib.pyplot as plt

# 1. 데이터 로드 및 상관계수 계산 (숫자형만 선택)
df = sns.load_dataset('iris')
corr = df.select_dtypes('number').corr(method='pearson')

# 2. 히트맵 시각화 (YlGnBu 컬러맵)
sns.heatmap(corr, annot=True, cmap='YlGnBu')
```



결과 해석 포인트

◎ 핵심 동인 (Key Driver)

Petal_Length ↔ Width (0.96) 꽃잎의 길이와 너비는 매우 강한 양의 상관관계를 가짐. 하나를 알면 다른 하나도 거의 정확히 예측 가능.

⊖ 약한 관계 / 독립성

Sepal_Width 는 다른 변수들과 상관관계가 낮거나 음수(-0.1 ~ -0.4)를 보임. 품종을 구분하는 독특한 특징일 가능성

[실습 2] OLS 회귀 모델링 및 결과 해석

OLS Regression Results


Dep. Variable: Petal Length Method: OLS

R-SQUARED (결정계수)		ADJ. R-SQUARED		
0.760 ✔		0.758		
모델이 데이터를 76% 설명함		변수 개수 보정값		
F-STATISTIC		PROB (F-STATISTIC)		
468.6		1.04e-47		
Variable	coef	P> t	[0.025	0.975]
Intercept	-7.1014	0.000	-8.200	-6.000
Sepal_Length ★	1.8584	0.000	1.689	2.028

ℹ P < 0.05 : 통계적으로 유의미함 (Green Highlight)

회귀 직선 시각화 (Line of Best Fit)

$y = 1.86x - 7.10$



PYTHON

```
import statsmodels.formula.api as smf
# '종속변수 ~ 독립변수' 형태의 수식 사용
model = smf.ols('petal_length ~ sepal_length', data=iris).fit()
print(model.summary())
```


심화 분석 - 다항 회귀 (Polynomial Regression) | 비선형 관계 모델링

📊 단순 선형 회귀 (Degree=1)

$R^2 = 0.62$



$$y = ax + b$$

Underfitting (과소적합):

데이터의 곡선 패턴을 직선으로 설명하려다 보니 오차가 큼.

📈 다항 회귀 (Degree=3)

$R^2 = 0.94$



$$y = ax^3 + bx^2 + cx + d$$

Better Fitting (적합):

데이터의 곡률을 유연하게 반영하여 설명력(R^2) 상승.

STATSMODELS FORMULA

```
import statsmodels.formula.api as smf
# 3차항까지 추가하여 모델링
model = smf.ols('y ~ x + I(x**2) + I(x**3)', data=df).fit()
```

💡 핵심 비교

- **설명력:** 다항 회귀가 훨씬 높음
- **주의점:** 과도한 차수 = 과적합(Overfitting) 위험

핵심 요약 (Key Takeaways)



상관관계는 인과관계가 아닙니다 (Correlation $\neq$ Causation)

두 변수가 같이 움직인다고 해서, 하나가 다른 하나의 원인이라고 단정 짓지 마세요. 추가적인 실험과 도메인 지식이 필요합니다.



비즈니스 관점

- **핵심 동인(Key Driver)** 발굴:
매출, 만족도와 연관된 중요 인자를 상관 분석으로 선별
- **수치 기반 예측:**
단순 감이 아닌, 회귀 방정식($y=ax+b$)으로 구체적 목표 수립



기술 관점

- **도구 선정:**
선형 관계는 피어슨, 순위는 스피어만, 모델링은 OLS
- **최소제곱법(OLS):**
오차(잔차)의 제곱 합을 최소화하는 최적의 선 찾기



주의 및 다음 단계

- **유의성 검증 (P-value):**
 $p < 0.05$ 확인 필수. 우연에 의한 패턴인지 의심하기
- **모델 개선:**
단순 선형으로 부족하면 다항 회귀나 다중 회귀로 확장