

암기보다는 이해를

과적합 방지와 일반화 전략



과적합 현상

Train Error vs Val Error



가중치 규제

L1 / L2 Regularization



일반화 능력

Dropout & Ensemble



강의 목표

과적합의 원인을 시각적으로 이해하고, 가중치 규제(L1/L2)와 드롭아웃이 어떻게 모델의 복잡도를 제어하여 일반화 성능을 높이는지 학습합니다.



과적합(Overfitting)

"기출문제 답만 외운 학생"

TRAINING DATA

연습 문제집 (기출)

100점

TEST DATA

실전 수능 시험

0점

“ 문제의 **본질(원리)**은 모른 채
답안지의 **패턴(노이즈)**만 암기했습니다. ”

훈련은 완벽한데, 실전은 엉망?

모델이 학습 데이터에 **지나치게 최적화**되어 일반화 성능이 떨어지는 현상



극심한 성능 격차

Train Error는 매우 낮지만, Val/Test Error는 매우 높게 나타나는 것이 전형적인 증상입니다.



노이즈까지 학습함

데이터에 섞인 무의미한 잡음(Noise)이나 예외적인 패턴까지 '규칙'으로 착각하고 학습해 버렸습니다.



원인: 과도한 표현력(Capacity)

데이터의 복잡도에 비해 모델이 너무 크거나(Deep), 학습을 너무 오래 시켰거나, 규제가 부족했습니다.




목표: '암기'에서 '이해'로

모델이 데이터 하나하나를 외우는 것이 아니라, 전체적인 데이터 분포의 **일반적인 규칙**을 배우도록 해야 합니다.

⚠ BAD MODEL

복잡한 곡선 (과적합)

데이터의 **노이즈**까지 억지로 학습하여
곡선이 지나치게 구불구불해짐



✗ 높은 분산 (High Variance)

데이터가 조금만 바뀌어도 모델이 크게 변함

↘ 새로운 데이터에 취약


훈련 에러는 낮지만, 검증 에러는 높음

VS

✓ GOOD MODEL

부드러운 곡선 (일반화)

노이즈는 무시하고 데이터의
본질적인 추세만을 포착함



✓ 적절한 편향 (Balanced Bias)


데이터의 주요 패턴을 안정적으로 설명

↗ 새로운 데이터에 강함

훈련 성능과 검증 성능의 격차가 적음

모델 표현력과 데이터 복잡도의 불균형

Capacity Gap: 모델이 데이터보다 훨씬 더 똑똑(복잡)할 때, 모델은 '이해'하는 대신 '암기'를 선택합니다.



데이터의 한계

- 훈련 데이터 샘플 수 부족
- 데이터 내 높은 노이즈(잡음) 비율
- 특정 클래스에 편향된 분포



모델의 과잉 용량

- 지나치게 많은 파라미터 수
- 불필요하게 깊은 신경망 층(Layer)
- 데이터 패턴보다 더 복잡한 모델 구조




학습 설정의 문제

- 규제(Regularization) 기법 미적용
- 과도하게 긴 학습 시간 (Too many Epochs)
- 훈련 데이터가 검증셋에 누수됨

Loss Curve (손실 곡선)

● Training Loss ● Validation Loss



언제 학습을 멈춰야 할까?

Train Error와 Validation Error의 격차(Gap)가 핵심 신호입니다.

🔍 최적 지점 (Optimal Point)

Validation Error가 가장 낮은 지점입니다. 이때가 모델의 일반화 성능이 가장 좋은 순간입니다. 보통 이 지점의 모델 가중치를 저장(Checkpoint)합니다.

⚠️ 과적합 시작 (Overfitting Start)

Train Error는 계속 줄어듭니다, Validation Error가 다시 증가하기 시작하는 시점입니다. 모델이 훈련 데이터의 '노이즈'를 암기하기 시작했다는 신호입니다.

💡 Early Stopping (조기 종료)


검증 에러가 더 이상 낮아지지 않을 때 학습을 자동으로 중단시키는 기법을 활용하세요.

1 SOLUTION #1

데이터가 많을수록 '꿈수'는 통하지 않는다

데이터의 양이 늘어나면 노이즈의 영향력은 줄어들고, 진짜 패턴만 남게 됩니다.


데이터 부족 (적은 샘플)



DATA INCREASE



데이터 충분 (많은 샘플)



꿈수 방지

데이터가 많아지면 모델이 모든 예외 케이스(노이즈)를 외우는 것이 불가능해져, **보편적 규칙**을 찾게 강제됩니다.



결정 경계의 평활화

샘플이 촘촘해질수록 이상치(Outlier)의 영향력이 희석되어, 모델의 결정 경계선이 더 **부드럽고 안정적**으로 변합니다.



직관적 비유


"기출문제를 100문제만 풀면 답을 외울 수도 있지만, **10,000문제**를 풀면 출제 원리를 이해해야만 합니다."

2 SOLUTION #2

모델이 복잡해지면 '벌금'을 부과하라

손실 함수에 규제항(Regularization Term)을 추가하여, 가중치(w) 값이 너무 커지는 것을 억제합니다.

규제 없음 (No Penalty)



가중치 값이 매우 크고 들쭉날쭉함

ADD PENALTY

$$+ \lambda ||w||$$



규제 적용 (Regularized)



가중치 크기가 전체적으로 작아짐



벌금(Penalty)의 원리

$Loss = Error + Penalty$. 모델이 정답을 맞추더라도 가중치가 너무 크면 손실 값을 높여서, **단순한 모델**을 선호하게 만듭니다.




L2 규제 (Ridge)

가중치의 제곱합($||w||^2$)을 벌금으로 사용. 모든 가중치를 골고루 작게 만들어 **부드러운 곡선**을 만듭니다.



L1 규제 (Lasso)

가중치의 절댓값 합($||w||_1$)을 벌금으로 사용. 불필요한 가중치를 **완전히 0으로** 만들어 특성을 선택하는 효과가 있습니다.



Lasso Regression

모서리에 걸리면 0이 된다 (희소성)

Minimize: $Loss(w)$ subject to $\|w\|_1 \leq C$



다이아몬드 제약 (Diamond Constraint)

L1 규제는 가중치 절대값의 합을 제한합니다. 기하학적으로 좌표축에 뾰족한 꼭짓점이 있는 마름모 형태를 띕니다.




0으로 만들기 (Sparsity)

손실 함수의 등고선이 축 위의 꼭짓점과 만날 확률이 매우 높습니다. 이 때 해당 축의 가중치는 0이 됩니다.



특성 선택 (Feature Selection)

중요하지 않은 변수들의 가중치가 0이 되어 사라지므로, 자동으로 변수를 선택하는 효과가 있습니다.



Ridge Regression

원형 울타리 안에서 최적의 타협점 찾기

Minimize: $Loss(w)$ subject to $\|w\|^2 \leq C$

○ 원형 제약 (Circular Constraint)

L2 규제는 원점으로부터의 거리(유클리드 거리)를 제한합니다. 이는 기하학적으로 원(Circle) 또는 구(Sphere) 형태를 띕니다.

✂ 골고루 작게 (Weight Decay)

원의 특성상 어느 한 방향으로 뺄지 않습니다. 따라서 특정 가중치를 0으로 없애기보다는, 모든 가중치를 전체적으로 작게 만듭니다.


🎯 안정적인 접점

손실 함수의 등고선이 원형 제약과 만나는 접점에서 최종 해(w^*)가 결정됩니다.


학습 시 무작위로 연결을 끊는 파격적 전략

"핵심 인재 한두 명에게만 의존하지 마라!" — 모든 뉴런이 스스로 역할을 찾게 만드는 훈련법

Standard Neural Net



Dropout Neural Net ($p=0.5$)



드롭아웃의 정의

- 학습 과정에서 은닉층의 일부 뉴런을 확률 p 로 비활성화 (0으로 설정)
- 매 미니배치(Mini-batch)마다 다른 뉴런이 랜덤하게 제거됨



직관적 비유: 팀 프로젝트

- 특정 '에이스' 팀원(강한 특징)이 없을 때도 성과를 내야 함
- 다른 팀원들이 버스를 타지 않고, 각자 독립적인 역할을 수행하게 강 제함



공적응(Co-adaptation) 방지

- 뉴런들이 서로 복잡하게 얽혀 특정 패턴을 암기하는 것을 막음
- 결과적으로 더 견고(Robust)하고 일반화된 특징을 학습

WITHOUT DROPOUT

일반 신경망 (Standard)

모든 뉴런이 촘촘하게 연결되어
특정 **강한 신호**에 다른 뉴런들이 물어감



공적응 (Co-adaptation)

뉴런들이 서로의 실수에 의존하며 복잡하게 얽힘

특정 뉴런 과의존

핵심 인재 몇 명에게만 의존하는 취약한 구조

VS

WITH DROPOUT

드롭아웃 적용 (Dropout)

학습 때마다 무작위로 파트너가 사라져
홀로서기를 강제함



강건한 특징 학습 (Robust Features)

누가 없어도 정답을 맞출 수 있는 독립적 특징 발견

앙상블 효과 (Ensemble)

매번 다른 구조의 작은 네트워크들이 합심하는 효과

집단지성 (Ensemble)



i 서로 다른 수많은 '얇은 신경망'들의 의견을 종합하는 효과

DROPOUT EFFECT

하나의 모델, 다수의 지능

학습마다 무작위로 뉴런이 탈락되면서, 마치 **매번 다른 구조의 모델을 학습**하는 것과 같은 효과를 냅니다.



매번 다른 모델 학습 (Thinned Network)

미니배치(Mini-batch)마다 서로 다른 뉴런들이 비활성화되므로, 사실상 2ⁿ개의 서로 다른 서브 네트워크를 학습하는 셈입니다.



암묵적 앙상블 (Implicit Ensemble)

여러 모델의 예측을 평균 내면(Ensemble) 개별 모델보다 성능이 좋아지는데, 드롭아웃은 단일 모델 내에서 이 효과를 구현합니다.



분산 감소 및 일반화 향상

여러 구조의 의견이 합쳐지면서 특정 데이터나 노이즈에 대한 편향이 줄어들고, **일반화 성능(Generalization)**이 크게 향상됩니다.

#Model_Averaging

#Sub_Networks

#Robustness

STEP 1

학습 (Training)

무작위로 뉴런 끄기



- ✓ 확률 p 로 뉴런 비활성화
- ✓ 매 배치마다 다른 구조 학습
- 🎲 무작위성(Stochastic) 존재



KEY IDEA

스케일링 (Scaling)

신호의 총량 맞추기



학습 때는 일부만 켜져 있었지만, 테스트 때는 모두 켜집니다. 신호가 갑자기 강해지는 것을 막아야 합니다.

Expectation $E[y]$ 유지



STEP 2

추론 (Test)

모든 뉴런 사용



- ✓ 모든 뉴런 활성화
- ✓ 평균적인 거동 예측
- 📊 결정론적(Deterministic)



실전 팁: Inverted Dropout (역 드롭아웃)

테스트 단계의 연산 효율을 위해, 학습 시에 미리 출력을 $1/(1-p)$ 로 키워놓고, 테스트 때는 아무런 조작 없이 그대로 사용하는 방식이 표준입니다.

데이터가 부족하다면 만들어서 쓰자!

💡 핵심 아이디어

이미지를 회전하거나 자르는 등 레이블(정답)이 변하지 않는 선에서 데이터를 인위적으로 변형하여 학습 데이터의 양을 늘리는 기법입니다.



불변성(Invariance) 학습

"고양이가 뒤집혀도 고양이"라는 사실을 모델에게 가르칩니다.



과적합 강력 억제

모델이 학습 데이터를 단순히 외우는 것을 방해하여 일반화 능력을 키웁니다.



🖼️ 원본 (Original)

Sample: x



Augmented Samples



+1

↻ 회전 (Rotation)



+1

↔ 좌우 반전 (Flip)



+1

✂ 자르기 (Crop)



+1

★ 노이즈 (Noise)

"좋은 모델은 정답을 **와우저** 않고 데이터의 **규칙을 이해**합니다"

일반화(Generalization) 성능이 곧 모델의 실력입니다.



L2 규제 (Ridge)

모든 가중치를 골고루 작게 만들어 곡선을 부드럽게(Smooth) 편



L1 규제 (Lasso)

불필요한 특징의 가중치를 0으로 만들어 모델을 단순화(Sparse)



드롭아웃 (Dropout)

뉴런 간의 공적응을 막고 앙상블 효과로 일반화 성능 극대화



데이터 증강

데이터의 다양성을 확보하여 모델이 불변성(Invariance)을 학습하게 함

💡 실무 적용 팁: 과적합 방지 워크플로우

1

데이터 확보

최대한 많이 + 증강

2

모델 용량 설정

충분히 복잡하게 시작

3

규제 적용

Dropout, L2 추가

4

모니터링

Val Loss 증가 시 중단