

정규화 선형회귀

Regularized Linear Regression

- 과적합 (Overfitting) 방지
- 일반화 (Generalization) 성능 향상
- 핵심:** Lasso · Ridge · Elastic Net

목차 Agenda

정규화 선형회귀 강의의 주요 흐름



문제 정의

과적합(Overfitting)의 정의와 위험성 징후

01



해결 방안

정규화(Regularization) 원리와 비용 함수 재정의

02



주요 기법

Lasso · Ridge · Elastic Net 기법의 특징 비교

03



실습 및 요약

과적합 재현 실습 및 모델 성능 핵심 요약

04

문제 정의: 과적합(Overfitting)의 위험

- **현상: 노이즈 과도 학습**

데이터의 핵심 패턴 외에 사소한 노이즈까지 암기하여, 모델 구조가 불필요하게 복잡해지는 현상


- **결과: 일반화(Generalization) 실패**

학습 데이터(Train Set) 설명력은 완벽하나, 새로운 데이터(Test Set)에 대한 예측 성능은 급격히 저하됨

- **징후: 회귀 계수의 비정상적 폭주**

모든 데이터 포인트를 억지로 연결하려는 과정에서 가중치(Weight) 절댓값이 통제 불가능할 정도로 발산

과적합 패턴 시각화



Training Set
정확도 높음 (Low Error)

Test Set
정확도 낮음 (High Error)

해결 방안: 정규화(Regularization)

- 핵심 아이디어: 복잡도에 가격표 붙이기

오차만 줄이는 것이 아니라, **모델의 복잡도(계수의 크기)**도 함께 최소화해야 할 비용(Cost)으로 간주합니다.

- 비용 함수(Cost Function) 재정의

기존 오차 함수(\$Error\$)에 규제항(\$Penalty\$)을 더하여, **오차와 계수 크기를 동시에 최소화** 합니다.

- 기대 효과: 일반화 성능 향상

특정 변수의 과도한 영향력을 억제하고 모델을 단순화하여, **새로운 데이터에 대한 예측력**을 높입니다.

정규화 공식

$$\text{Cost} = \text{Error} + \text{Penalty}$$

오차 규제항



데이터 적합 (Fitting)

실제 데이터와 예측값의 차이 최소화



복잡도 제어 (Control)

회귀 계수(Weight)가 너무 커지지 않도록 억제

💡 "적당히 틀리더라도, 단순한 모델이 강하다"

주요 기법 비교: Lasso vs Ridge

- **Lasso (L1): 변수 선택의 힘**

계수 절댓값 합에 페널티를 부여하여 불필요한 변수의 계수를 0으로 만듭니다. **변수 선택(Feature Selection)**이 필요한 희소 모델에 적합합니다.


- **Ridge (L2): 전반적인 규제**

계수 제곱 합에 페널티를 주어 크기를 전반적으로 줄이지만 0으로 만들지는 않습니다. 변수 간 **상관관계(다중공선성)**가 높을 때 유리합니다.

- **Elastic Net: 장점 결합**

L1과 L2 규제를 혼합하여 변수 선택과 정규화 효과를 동시에 얻습니다. 상관된 변수 그룹을 함께 선택하거나 제거할 때 유용합니다.

Summary



Lasso

계수 0 (제거)
Sparse Model

L1



Ridge

계수 축소 (Shrink)
Multicollinearity

L2



Elastic Net

L1 + L2 혼합
Group Selection

Mix

[실습 1] 데이터 생성 및 기본 회귀(OLS) 적합

- 데이터 생성: 비선형 패턴과 노이즈

$y = \sin(2\pi x)$ 함수에 무작위 잡음을 추가하여 현실적인 비선형 데이터셋을 준비합니다.


- OLS 모델 적합과 도구 활용

`statsmodels` 라이브러리의 OLS(Ordinary Least Squares)를 사용하여 기본적인 선형 회귀선을 학습시킵니다.

- 결과 분석: 과소적합의 한계

직선 형태의 모델은 데이터의 곡선 추세를 반영하지 못해, 패턴을 놓치는 **과소적합(Underfitting)**이 발생합니다.

OLS 결과 시각화



Real Data
비선형(Curve)



Prediction
단순 선형(Line)

[실습 2] 의도적 과적합 유도

- **설정: 9차 다항 회귀(Polynomial Regression)**

단순한 사인 파형 데이터($\sin 2x$)에 지나치게 복잡한 9차 다항식 모델을 강제로 적합시킵니다.


- **결과: 심각한 요동(High Variance)**

모든 노이즈 포인트까지 학습하려다 보니, 회귀 곡선이 위아래로 급격하게 진동하는 불안정한 모습을 보입니다.

- **징후: 회귀 계수(Weight)의 폭발**

데이터를 억지로 맞추는 과정에서 고차항의 계수 값이 비정상적으로 커지며 발산하는 현상이 발생합니다.

과적합(Overfitting) 시각화



Train Score
0.99

Test Score
0.45

[실습 3] 정규화 모델 적용 (Lasso & Ridge)

- **Lasso (L1): 변수 선택과 단순화**

L1_wt=1 설정 시, 영향력이 적은 변수의 계수를 **완전히 0으로 만들어 (Zeroing)** 모델을 가볍게 만듭니다.

- **Ridge (L2): 계수 축소와 안정화**

L1_wt=0 설정 시, 모든 계수의 크기를 **전반적으로 축소(Shrinkage)** 하여 과적합을 억제합니다.

- **구현: statsmodels 라이브러리**

OLS 객체의 `fit_regularized()` 메서드를 활용하며, `alpha`와 `L1_wt` 파라미터로 규제 강도와 방식을 조절합니다.

계수 변화 시각화

Lasso Effect

Original



Sparse



High



0



High



0

Original



Shrunk

Mid

Low

Mid

Low

하이퍼파라미터(Alpha)의 영향

- 규제 강도(Alpha)의 역할

Alpha는 페널티 강도를 조절하는 핵심 변수입니다. 값이 클수록 규제가 강해져 모델이 단순해지고, 작을수록 데이터에 민감해집니다.


- 계수 수렴 경로(Lasso Path)

Alpha가 증가할수록 회귀 계수들이 점차 0으로 수렴 하며, 이 과정에서 불필요한 변수가 제거되는 변수 선택 효과가 발생합니다.

- 최적 튜닝의 필요성

과적합과 과소적합 사이의 균형점을 찾기 위해 교차 검증(Cross Validation) 으로 오차가 최소화되는 최적의 Alpha를 탐색해야 합니다.

📈 Lasso Coefficient Path



← Complex (Overfit)

Simple (Underfit) →

핵심 요약: 모델의 완성

- 일반화 성능 확보

복잡도에 페널티를 부여하여 새로운 데이터 환경에서도 **안정적인 예측을 보장** 함.

- 목적에 맞는 기법 선택

변수 제거가 필요하면 **Lasso**, 전반적인 영향력 감소가 필요하면 **Ridge**를 전략적으로 활용.

- Alpha 튜닝의 중요성

모델 성능의 핵심인 규제 강도(Alpha)는 반드시 **교차 검증(CV)** 을 통해 최적화 필수.

Field Checklist



과적합 방지 확인

Check Generalization Gap



Alpha 최적화 완료

Validate with Cross-Validation



예측 신뢰도 확보

Confirm Reliable Predictions