

다중회귀분석 정복하기

이론부터 파이썬 실전까지

복잡한 비즈니스 문제의 인과관계를 파헤치는 통계적 도구



왜 다중회귀분석인가?

Why Multiple Regression Analysis?



단순회귀의 한계 (Limitation)

현실 세계의 결과는 단일 원인으로 설명 불가 예: 주택 가격(Y) ≠ 평수(X)만으로 결정되지 않음



다중 요인 반영 (Multivariate)

방 개수, 학군, 위치 등 다양한 독립변수(X)가 종속변수(Y)에 미치는 복합적 영향을 동시에 분석




분석의 목적 (Objective)

단순회귀를 넘어 현상을 정교하게 모델링하고
변수 간 인과관계 규명 및 미래 예측 정확도 확보



방 개수 (\$X_2\$)



주택 가격 (Y)
위치 (\$X_3\$)

핵심 원리 (Deep Dive)

데이터를 설명하는 최적의 방정식 찾기

REGRESSION EQUATION

$$Y = \beta_0 + \beta_1 X_1 + \dots + \beta_p X_p + \epsilon$$

- Y** 종속변수 (Target): 예측하고자 하는 결과 값 (Label)
- X** 독립변수 (Feature): 원인이 되는 설명 변수들
- β** 회귀계수 (Coefficient): 각 변수의 영향력 (가중치/기울기)
- ϵ** 잔차 (Error): 모델이 설명하지 못하는 오차

💡 Analogy

온도 (X_2)



원두 (X_1)



최적 비율



맛있는 커피 (Y)


Insight: 커피 맛(Y)을 결정하는 최적의 원두·온도 배합 비율(β)을 찾는 과정

실전 분석: 데이터 준비 및 모델링



데이터 로드

Load Dataset



데이터 탐색

EDA & Cleaning



데이터 분할

Train / Test Split



모델 학습

Model Fitting

KEY ACTIONS

- ✓ 데이터 적재: 원본 데이터셋 로드 및 기초 통계량(Shape, Info) 확인
- ✓ 탐색적 분석: 결측치·이상치 정제 및 주요 변수 간 상관관계 시각화
- ✓ 데이터 분할: 모델 검증을 위해 학습(Train) 및 테스트(Test) 셋으로 분리
- ✓ 모델링: 선형회귀(Linear Regression) 알고리즘 학습 및 회귀계수 도출

모델 성능 평가 (Evaluation)



결정계수 (R^2)

Model Explanatory Power



교차 검증 (CV)

Model Robustness



RMSE (오차)

Prediction Error

KEY TAKEAWAYS

- ✓ 결정계수(R^2): 모델이 데이터를 설명하는 비율로 1에 가까울수록 성능 우수함.
- ✓ 교차 검증(CV): 반복 학습을 통해 데이터 편향을 줄이고 과적합 여부를 검증함.
- ✓ RMSE: 예측값과 실제값의 오차 평균이며 수치가 낮을수록 정밀함.

심층 분석 및 해석 (Statsmodels)



Scikit-learn

- 모델의 **예측(Prediction)** 성능과 활용성 극대화
- 머신러닝 파이프라인 및 워크플로우 통합 용이
- 간결한 API 구조로 빠른 모델링 가능



Statsmodels

- 모델의 **해석(Interpretation)**과 통계적 검정 특화
- 상세한 통계 요약표(Summary Table) 제공
- 변수별 유의성(P-value) 및 신뢰구간 확인



P-value

통계적 유의성 판단 (< 0.05)



Adj. R-squared

변수 수 패널티 반영 결정계수

모델 가정 검증 (Diagnostics)

좋은 회귀 모델이 갖춰야 할 필수 조건 확인



잔차의 독립성 (Independence)

더빈-왓슨(Durbin-Watson) 통계량 확인

→ 2에 가까울수록 자기상관 없이 독립적임



잔차의 정규성 (Normality)

히스토그램과 Q-Q Plot을 통한 시각적 점검

→ 잔차가 정규분포(Bell Curve) 형태를 따르는지 확인




이상치 및 영향점 (Outliers)

Cook's Distance 등을 이용해 모델 왜곡 방지

→ 전체 추세에서 벗어난 특이 관측치 식별 및 제거

정규성 (Normality)



정규분포 형태 (Bell Curve)

잔차 분포 (Residuals)



무작위 분포 및 이상치 확인

핵심 요약 (Key Takeaways)

비즈니스 문제 해결과 기술적 구현의 완벽한 조화



비즈니스 관점

- 문제 해결을 위한 '핵심 동인(Driver)' 식별 및 우선순위 파악
- 각 요인의 영향력을 수치로 정량화하여 객관적 의사결정 지원



기술 관점

- Scikit-learn: 대규모 데이터 처리에 최적화된 빠른 예측 모델링
- Statsmodels: 정교한 통계 검정으로 결과의 신뢰성 및 인과성 확보



데이터 의사결정의 핵심: '정확한 예측'과 '명확한 해석'의 조화