

```
import pandas as pd
import numpy as np
df = pd.read_csv('data.csv')
df.head()
df.describe()
```

📖 1단계 - 데이터 핸들링 기반 다지기

데이터 전처리 1강: 환경 구축 & Pandas 기초

"전처리의 80%는 **Pandas** 숙련도에서 결정됩니다"

강의 개요 및 학습 목표

🎯 학습 목표

이번 강의를 통해 여러분은 다음 4가지 핵심 역량을 갖추게 됩니다.

✔ 전처리의 중요성 이해

'Garbage In, Garbage Out'의 의미를 파악하고, 데이터 품질이 분석 결과에 미치는 영향을 이해합니다.

✔ 분석 환경 구축

Jupyter Notebook과 Google Colab의 특징을 비교하고, 자신에게 맞는 분석 환경을 설정합니다.

✔ Pandas 데이터 구조 파악

Series와 DataFrame의 차이를 이해하고, 다양한 소스(CSV, Excel 등)의 데이터를 로드합니다.

✔ 기본 탐색 기술 습득

head(), info(), describe() 등의 필수 메서드를 활용하여 데이터의 기초 정보를 빠르게 파악합니다.

≡ 오늘의 흐름

01

데이터 사이언스 프로세스 & 전처리

02

환경 설정 (Jupyter vs Colab)

03

Pandas 기초 (DataFrame, Series)

04

데이터 로드 (CSV, Excel, JSON)


05

데이터 탐색 (head, info, describe)

06



📄 실습: 공공 데이터 로드

데이터 사이언스 프로세스와 전처리의 역할



⚠ Garbage In, Garbage Out (GIGO)

"쓰레기가 들어가면 쓰레기가 나온다" - 머신러닝 모델의 성능은 입력 데이터의 품질에 절대적으로 의존합니다.



✓ 전처리는 데이터를 "Golden Input"으로 만드는 과정

📌 핵심 전처리 체크포인트



데이터 구조 및 타입

스키마 일치 여부 확인, 날짜/숫자 타입 변환



결측치(Missing Values) 처리

삭제(Drop)할 것인가, 대체(Imputation)할 것인가?



이상치(Outlier) 탐지

분포를 벗어난 값 식별 및 보정/제거



데이터 변환(Scaling)

정규화, 표준화, 인코딩(One-hot) 등 모델 맞춤 변환

환경 설정: Jupyter vs Colab



OPTION 1

Jupyter Lab

로컬 컴퓨터에서 실행하며, 파일 관리가 용이하고 오프라인에서도 작업이 가능합니다.

> 설치 및 실행

```
$ pip install jupyterlab  
$ jupyter lab
```

핵심 장점

- ✓ 로컬 파일 시스템 직접 제어
- ✓ 인터넷 없이 작업 가능
- ✓ 다양한 확장 프로그램 (Extensions)



OPTION 2

Google Colab

구글 서버를 활용하며 별도 설치 없이 브라우저에서 즉시 사용 가능합니다.

🔗 접속 주소

colab.research.google.com



핵심 장점

- ✓ 환경 설정 불필요 (Zero Config)
- ✓ 무료 GPU/TPU 사용 지원
- ✓ Google Drive 연동 및 공유 용이



필수 패키지

pandas

numpy

openpyxl

* Colab에는 이미 설치되어 있습니다.

Pandas의 핵심: DataFrame과 Series



Series

1차원 라벨 배열


데이터프레임을 구성하는 기본 단위로, **하나의 열(Column)**과 유사합니다.
모든 데이터는 동일한 타입(dtype)을 가집니다.

VISUALIZATION

Index	Value
0	10
1	20
2	30

DataFrame 구조 시각화

Index + Columns + Values



DataFrame

2차원 테이블 구조

여러 개의 Series가 모여 열(Column)을 이루며, **행(Row)**과 **열(Column)** 인덱스를 모두 가집니다.

- ✓ 2차원 구조: 행과 열로 데이터 정렬
- ✓ 이종 데이터: 컬럼별 다른 타입 가능
- ✓ 크기 가변: 데이터 추가/삭제 용이

</> 핵심 속성 및 메서드

* 자주 사용하는 필수 명령어

`.shape`

행/열 크기 확인 (Tuple)

`.dtypes`

각 컬럼의 데이터 타입

`.info()`

Method

데이터 요약 정보 출력

`.describe()`

Method

기술 통계량 요약



데이터 로드: CSV, Excel, JSON

파일 형식

지원하는 주요 포맷

- CSV


CSV (Comma)
가장 보편적인 텍스트 포맷. 쉼표로 데이터 구분.
- XLSX

Excel (XLSX)
스프레드시트. 시트(Sheet) 단위 로드 지원.
- JSON

JSON
웹 표준 포맷. 중첩된 계층 구조 데이터.

로드 프로세스 시 각화

Input → Process → Output



주의사항

로드 전 체크리스트

- ⚠

Encoding (인코딩)
한글 파일 깨짐 시 인코딩 옵션 변경 필수. (하단 참조)
- 📁

File Path (경로)
상대경로(./)와 절대경로(/) 구분. 슬래시(/) 방향 주의.
- ⚙️

Key Options
header, index_col, sep 등 데이터 구조에 맞는 옵션 설정.

</> 인코딩 옵션 (Encoding Options)

* 한글 깨짐 해결을 위한 필수 옵션

- 'utf-8'

표준 (기본값)
- 'cp949'

Windows 한글 (권장)
- 'euc-kr'

구형 한글 시스템
- 'utf-8-sig'

Excel CSV 호환

데이터 파악을 위한 필수 메서드



미리보기

데이터 샘플 확인

`.head(n)`

Top

상위 n개 행 출력 (기본 5개)

`.tail(n)`

Bottom

하위 n개 행 출력 (기본 5개)

`.sample(n)`

Random

무작위 n개 행 추출

탐색 프로세스

Step-by-Step



1 데이터미리보 기

로드 상태 및
패턴 확인

2 구조/정보 파악

타입 및
결측치 진단

3 통계적특성 분석

분포 확인 및
이상치 탐색



구조 분석

메타데이터 확인

`.info()`

Summary

전체 요약 정보 (타입, 메모리 등)

`.describe()`

Stats

기술 통계량 (평균, 표준편차 등)

`.dtypes`

Types

각 컬럼별 데이터 타입만 확인

핵심 메서드 비교

메서드	주요 목적	반환 내용	활용 시점
<code>.head()</code>	데이터 확인	상위 5개 행 (DataFrame)	로드 직후 데이터 정상 여부 판단
<code>.info()</code>	구조 파악	타입, 개수, 결측치, 메모리	전처리 전 데이터 전체 스펙 진단
<code>.describe()</code>	통계 분석	주요 기술 통계량 (DataFrame)	수치 데이터의 분포 및 이상치 탐색

실습: 공공 데이터 포털 CSV 불러오기

🎯 실습 목표

실제 공공 데이터를 내 컴퓨터로 가져와서 Pandas DataFrame으로 변환하고, 데이터의 기본 구조를 파악합니다.

분석 단계 (Jupyter / Colab)



3

데이터 로드 (Load)

```
import pandas as pd # 파일 경로에 주의하세요
df = pd.read_csv('./data/raw/my_data.csv', encoding='utf-8')
```

4

기본 정보 확인 (Check)

데이터가 올바르게 들어왔는지 행/열 개수와 미리보기를 수행합니다.

```
print(df.shape)
print(df.head())
df.info()
```

← 필수

5

🔥 [과제] 결측치 상위 5개 컬럼 찾기

```
# 결측치(NA) 개수 확인 및 정렬
result = df.isna().sum().sort_values(ascending=False).head(5)
print(result)
```



한글 깨짐 해결 Tip

CSV 로드 시 `UnicodeDecodeError` 가 발생하면, `encoding='cp949'` 또는 `encoding='euc-kr'` 옵션을 추가해보세요.